

Repte Smadex per BrainrotAI

Pau Duran Mayol, Aitor Bolige Cubas, Arnau Nomen Valls & Alejandro Balboa Ruiz



El Repte: Dades vs. Velocitat

Smadex opera en un entorn de Real-Time Bidding on cada mil·lisegon té un cost d'oportunitat. Per començar hem fet el següent:

- ✓ Visualització de les dades amb Dask i inspecció de taules, columnes i valors. Deteccio de forta inflació de nuls.
- ✓ Selecció iterativa de features: Hem aplicat "prova-error" per seleccionar les variables més útils.

buy d14	buy d28	iap revenue d7	iap revenue d14	iap revenue d28	...	user bundles l28d	weekend ratio	weeks since first seen	wifi ratio
1	1	2.147718	2.147718	2.147718	...	[88981729bd5c1e5aea9acd4bce00a2531e9e98f7, 25c...	0.019802	6.0	0.913366
0	0	0.000000	0.000000	0.000000	...	None	NaN	NaN	NaN
0	0	0.000000	0.000000	0.000000	...	[6506b7e0a24666debd08f74266800f2eb154df5a, 150...	0.399021	6.0	0.999388
0	0	0.000000	0.000000	0.000000	...	[2b472e3dc96f1847490d7411b25e12ed417b9714, 3ba...	0.121547	6.0	1.000000
0	0	0.000000	0.000000	0.000000	...	[1031535cf2a1315422fd05d321349bcd3c3ffc04, 478...	0.293285	6.0	0.160243
0	0	0.000000	0.000000	0.000000	...	None	NaN	NaN	NaN
0	0	0.000000	0.000000	0.000000	...	[d8538ce27256d97f754711d9c9dd4ea533a113c8, e40...	0.125000	6.0	0.000000
0	0	0.000000	0.000000	0.000000	...	[54730dad0d716b50e623a155d96022ffb6e6862c4, f62...	0.264826	6.0	0.959002
0	0	0.000000	0.000000	0.000000	...	None	NaN	NaN	NaN
0	0	0.000000	0.000000	0.000000	...	None	NaN	NaN	NaN
1	1	119.990000	119.990000	119.990000	...	[d39a9be4be5f47b90f2bd21fa7df498ed62e3bb2, daf...	0.270619	6.0	0.918814
0	0	0.000000	0.000000	0.000000	...	[05ff041df40aa024acefb29ff8fbfd1fb400625, 78e...	0.524590	6.0	1.000000
0	0	0.000000	0.000000	0.000000	...	None	NaN	0.0	NaN
0	0	0.000000	0.000000	0.000000	...	[8e50490225ba1cc51b6fc06c5a448e8730d3e2b2, 029...	0.317183	5.0	0.789406
0	0	0.000000	0.000000	0.000000	...	[4cf7d46fd79db25857965319dbb178411498fd2b]	0.183280	6.0	0.937299

Anàlisi Exploratòria i Iteracions




Fig 1. Matriu de Correlació Inicial

La nostra anàlisi inicial (Fig 1.) va revelar una forta correlació entre els indicadors binaris de compra (buyer_d7) i el volum d'ingressos, motivant diversos enfocaments:

✗ Intent 1: Kernel PCA

Intent de reducció de dimensionalitat no lineal. Descartat per cost computacional excessiu durant el pre-processament.

🕒 Intent 2: Two-Step Model

Classificació + Regressió. Vam obtenir un **MSLE de 0.23**, però vam descartar-ho.

✓ Solució Final: Single LGBM

Un enfocament unificat que equilibra millor la precisió i la latència.

Arquitectura de la Solució



Ingesta amb Dask

Utilitzem Dask per permeten escalar a datasets que superen la memòria RAM disponible.

Neteja i filtratge

- Filtrar columnes:
 - eliminar poc informatives (98% null)
 - null a 0 a columnes específiques
- Correcció de dades
 - Topografia categòrica
 - Errors numerics

Estabilització Logarítmica

Apliquem una transformació $\log_{1p}(\text{target})$. Per:

- Suavitzar variància dels ingressos
- Permet que el model aprengui millor: va més ràpid i es confon menys amb els casos extrems.



LightGBM Regressor

Útil perquè es ràpid y pràctic

- Tracta automàticament els valors nuls i les columnes de text (categories), així no cal netejar ni transformar gairebé res.
- Early stopping fa que el model pari de millorar quan ja no treu més profit, així no es sobreentrena ni perd temps.

Triatge de variables


✓ Càlcul features + importants a partir del LGBM Classifier:

feature_importances_ = nombre de splits os s'usa cada feature.

-> ens donava pitjor resultat i les hem combinat seguint altres criteris + prova i error

✓ Detecció de Valor (Whales): Variables com whale_users_total_revenue utilitzen el passat per predir el futur amb alta fiabilitat.

✓ Fidelitat de l'Usuari: Mètriques com weeks_since_first_seen i avg_daily_sessions ens indiquen el compromís (engagement) real de l'usuari.



Futures Millores



Seleccio dels Features

L'objectiu és escollir aquelles que expliquen bé el model, evitar el soroll

Gràfics d'importància (feature importance).



De One-Step Model a Two-Step Model

En comptes de predir directament el revenue en una sola passada (One-Step), divideixes el problema en dues fases (Classifier i Regression)



Multitasking

Entrenar el model per a predir diverses labels alhora en comptes de només una. Pot ajudar perquè els features estan correlacionats i el model pot aprendre representacions conjuntes.

Gràcies per la vostra atenció

PREGUNTES?